

Relatório Técnico Detalhado: Análise de Localização para Novo CD Magalu Nordeste

Autores: Lucas Gomes Leria

Data: 27 de Setembro de 2025

Versão: 1.0

Sumário/Índice

- Resumo Executivo
- Introdução
 - Contextualização e Problema
- Metodologia e Materiais
 - Etapa 1: Planejamento e Definição
 - Validação dos KPIs Propostos
 - Plano Detalhado do Projeto
 - Avaliação das Ferramentas e Bibliotecas (Open Source)
 - Documentação Técnica e Executiva
 - Etapa 2: Coleta, Pré-processamento e Armazenamento de Dados (ETL)
 - Coleta de Dados
 - Pré-processamento (Limpeza e Transformação)
 - Armazenamento dos Dados
 - Fluxo ETL (Arquitetura de Dados)
 - Etapa 3: Análise, Modelagem e Otimização
 - KPI 1 — Tempo Médio de Entrega (Eficiência Logística)
 - KPI 2 — Custo de Aquisição Imobiliária (CapEx)
 - KPI 3 — Potencial de Consumo da Região (Demanda / Market Potential)
 - KPI 4 — Custo Operacional Total (TCO por Pedido)
 - Integração dos KPIs — Método de Decisão Final (MCDA)
 - Reprodutibilidade, Validação e Governança
 - Etapa 4: Visualização e Comunicação dos Resultados
 - Construção de Dashboards Interativos
 - Elaboração de Relatório Executivo e Preparação de Apresentação para Stakeholders
- Resultados
 - Resultados da Etapa 1
 - Resultados da Etapa 2
 - Resultados da Etapa 3
 - Resultados da Etapa 4 (Dashboard Streamlit)

- 5. Discussão
 - 5.1. Interpretação dos Resultados
 - 5.2. Limitações do Estudo e Pontos de Atenção
- 6. Conclusões
- 7. Recomendações
- 8. Referências Bibliográficas
- 9. Apêndices e Anexos

1. Resumo Executivo

Este relatório técnico detalha o processo de análise para determinar a localização mais estratégica para um novo Centro de Distribuição (CD) do Magalu no Nordeste, comparando Salvador e Recife. O projeto foi estruturado em quatro etapas: Planejamento e Definição, Coleta e Pré-processamento de Dados (ETL), Análise, Modelagem e Otimização, e Visualização e Comunicação dos Resultados. Utilizamos uma abordagem baseada em KPIs (Tempo Médio de Entrega, Custo de Aquisição Imobiliária, Potencial de Consumo da Região e Custo Operacional Total) e um método de Análise de Decisão Multicritério (MCDA - TOPSIS) para consolidar as avaliações. Os dados foram coletados de fontes abertas e processados para alimentar modelos preditivos e análises geoespaciais. A interface de visualização foi desenvolvida em Streamlit, permitindo a interação com os resultados e a simulação de cenários. A análise final, com pesos definidos por stakeholders, aponta Salvador como a localização mais estratégica, embora a decisão seja sensível à priorização do tempo de entrega. Este documento descreve as metodologias, ferramentas e implementações técnicas em cada etapa, bem como os resultados obtidos e as recomendações para futuras melhorias.

2. Introdução

2.1. Contextualização e Problema

A expansão e otimização da rede logística são cruciais para a competitividade no setor de varejo, especialmente em um mercado tão dinâmico quanto o brasileiro. O Magalu, buscando agilizar suas entregas e fortalecer sua presença no Nordeste, identificou a necessidade de estabelecer um novo Centro de Distribuição (CD) na região. A decisão estratégica recaiu sobre a escolha entre duas capitais: Salvador e Recife, ambas com potenciais e desafios distintos. O objetivo deste projeto foi fornecer uma análise robusta e baseada em dados para fundamentar essa decisão, respondendo a questões chave como a localização mais estratégica, os fatores que sustentam essa escolha e as metodologias empregadas. A complexidade da decisão exige a integração de múltiplos fatores, desde custos e eficiência logística até o potencial de mercado e a capacidade operacional, o que justifica a abordagem multicritério adotada.

3. Metodologia e Materiais

O projeto foi estruturado em quatro etapas principais, cada uma com objetivos e implementações técnicas específicas, conforme detalhado no documento `STEP-BY-STEP.MD`.

3.1. Etapa 1: Planejamento e Definição

Esta etapa inicial focou em estabelecer as bases do projeto, garantindo que os objetivos e a abordagem estivessem claramente definidos e alinhados.

3.1.1. Validação dos KPIs Propostos

Foram definidos quatro Key Performance Indicators (KPIs) como métricas centrais para a avaliação das cidades, garantindo que fossem relevantes, mensuráveis e alinhados aos objetivos estratégicos do Magalu. Os KPIs validados são:

- **Tempo Médio de Entrega (Eficiência Logística):** Medido em horas, representa a agilidade na distribuição para as principais capitais e cidades estratégicas da região.
- **Custo de Aquisição Imobiliária (Investimento Inicial - CAPEX):** Reflete o preço médio por m² de terrenos e galpões industriais, bem como o custo total de aquisição em cada cidade.
- **Potencial de Consumo da Região (Receita Esperada):** Quantifica a receita projetada com base em indicadores demográficos e de consumo.
- **Custo Operacional Total (Rentabilidade - OPEX por Pedido):** Estima o custo médio por pedido, incluindo componentes logísticos, mão de obra, energia e custos fixos.

3.1.2. Plano Detalhado do Projeto

O plano detalhou a estrutura do projeto em quatro etapas, atribuiu responsabilidades (Analista A para ETL, análise de custos e modelagem preditiva; Analista B para análise logística, simulação OSRM e mapas interativos), estabeleceu um cronograma estimado (total de ~30 a 40 dias) e definiu os entregáveis: Relatório Técnico Detalhado, Relatório Executivo e Dashboard Interativo.

3.1.3. Avaliação das Ferramentas e Bibliotecas (Open Source)

Uma seleção criteriosa de ferramentas e bibliotecas open source foi realizada para suportar todas as fases do projeto. As principais incluem:

- **Gestão e Colaboração:** Trello, Notion, Slack, GitHub.
- **Coleta e ETL:** Python (Requests, BeautifulSoup/Scrapy, Pandas, NumPy), PostgreSQL + PostGIS, GeoPandas.
- **Análise, Modelagem e Otimização:** GeoPandas, NetworkX, OSRM, Scikit-learn, Statsmodels, XGBoost, OR-Tools, SHAP, NumPy (para Monte Carlo).
- **Visualização e Comunicação:** Matplotlib, Seaborn, Plotly, Folium, Kepler.gl, Streamlit (prototipagem), Metabase (execução final).
- **Documentação e Reprodutibilidade:** Jupyter Notebooks, Markdown, LaTeX, MLflow.
- **Infraestrutura (Escala):** Docker, Kubernetes, Apache Airflow, Prometheus + Grafana.

3.1.4. Documentação Técnica e Executiva

Foi definida a estrutura para dois tipos de documentação: técnica (detalhes de dados, scripts, modelos, versionamento) e executiva (resumo, KPIs, gráficos, conclusão, storytelling), visando atender a diferentes públicos.

3.2. Etapa 2: Coleta, Pré-processamento e Armazenamento de Dados (ETL)

Esta etapa focou na construção de uma base de dados confiável e integrada a partir de fontes abertas.

3.2.1. Coleta de Dados

- `Etapa2_1_1_collect_real_estate_data.py` (**Coleta de Custos Imobiliários**): Utiliza `requests`, `BeautifulSoup` e `Selenium` para realizar web scraping de portais de imóveis (Zap Imóveis, Viva Real, OLX) em Salvador e Recife, coletando dados como preço, área e endereço. Este script é crucial para o KPI de Custo de Aquisição Imobiliária.
- `Etapa2_1_2_collect_road_network_data.py` (**Coleta de Malha Viária e Tempos de Entrega**): Consulta a `Overpass API` para extrair dados do OpenStreetMap e interage com o `OSRM` (Open Source Routing Machine) para calcular distâncias e tempos de viagem entre as capitais do Nordeste. Inclui um mecanismo de fallback com simulação em caso de falha do OSRM. Este script alimenta o KPI de Tempo Médio de Entrega.
- `Etapa2_1_3_collect_demographic_data.py` (**Coleta de Demografia e Potencial de Consumo**): Realiza requisições à API do IBGE para obter dados demográficos (população, PIB per capita, rendimento familiar) e inclui uma função de simulação para garantir a execução mesmo com indisponibilidade da API. Os dados coletados são fundamentais para o KPI de Potencial de Consumo da Região.

3.2.2. Pré-processamento (Limpeza e Transformação)

- `Etapa2_2_1_preprocess_real_estate_data.py` (**Pré-processamento de Dados Imobiliários**): Utiliza `Pandas` para limpar, normalizar e transformar os dados imobiliários brutos. Realiza a conversão de unidades, tratamento de valores ausentes, extração de CEP e georreferenciamento de endereços usando `geopy`, convertendo-os em coordenadas latitude/longitude. Este script prepara os dados para o KPI de Custo de Aquisição Imobiliária.
- `Etapa2_2_2_preprocess_road_network_data.py` (**Pré-processamento de Dados de Malha Viária**): Processa os dados de rotas, adicionando coordenadas geográficas e criando GeoDataFrames com `Pandas` e `GeoPandas`. Facilita a integração e análise geoespacial dos dados de tempo de entrega.
- `Etapa2_2_3_5_preprocess_demographic_data.py` (**Pré-processamento de Dados Demográficos**): Limpa, converte e padroniza os dados demográficos coletados, utilizando `Pandas`. Calcula o potencial de consumo e cria chaves unificadas para integração com outros datasets, preparando os dados para o KPI de Potencial de Consumo.

3.2.3. Armazenamento dos Dados

- `Etapa2_3_1_2_create_db_schema.py` (**Criação do Esquema do Banco de Dados**): Conecta-se a um banco de dados PostgreSQL, cria o banco `magalu_cd_analysis` (se necessário), habilita a extensão PostGIS e define o esquema das tabelas (`imoveis`, `rotas`, `demografia`, `consumo_potencial`, `estatisticas_comparativas`), incluindo colunas geométricas para dados espaciais.

- `Eteta2_3_3_load_data_to_db.py` (**Carregamento de Dados no Banco**): Utiliza `psycopg2` e `Pandas` para carregar os dados processados de imóveis, malha viária, demográficos e potencial de consumo nas tabelas correspondentes do PostgreSQL, garantindo a persistência e acessibilidade dos dados.

3.2.4. Fluxo ETL (Arquitetura de Dados)

- `Etapa2_4_magalu_etl_dag.py` (**DAG do Apache Airflow**): Este script define um Directed Acyclic Graph (DAG) para orquestrar o pipeline ETL. Ele integra as tarefas de coleta, pré-processamento e carregamento de dados em uma sequência lógica, garantindo a automação e o monitoramento do fluxo de dados. As funções dentro do DAG chamam os scripts Python individuais para cada etapa.
- `ANALISE_DO_DAG.MD` : Documenta a execução e validação do pipeline ETL, destacando sucessos, observações e pontos de atenção, como a necessidade de ajustes no scraping e o uso de simulação devido a problemas de API.

3.3. Etapa 3: Análise, Modelagem e Otimização

Esta etapa aplicou técnicas avançadas para responder aos KPIs e consolidar a decisão.

3.3.1. KPI 1 — Tempo Médio de Entrega (Eficiência Logística)

- `Etapa3.1_analyze_delivery_time.py` : Realiza a análise do tempo de entrega. Calcula estatísticas (média, mediana, percentis), simula incertezas via Monte Carlo, constrói um grafo da malha viária com `NetworkX` para análise de centralidade e gera isócronas com `GeoPandas` e `Shapely` para visualizar áreas de alcance em diferentes tempos de viagem. Depende dos dados processados da malha viária da Etapa 2.

3.3.2. KPI 2 — Custo de Aquisição Imobiliária (CapEx)

- `Etapa3.2_analyze_real_estate_cost.py` : Pré-processa dados imobiliários, treina um modelo hedônico (utilizando `GradientBoostingRegressor` do `Scikit-learn`) para estimar o preço por m² com base em características do imóvel. Calcula o custo total de aquisição (CAPEX) para as cidades, incluindo custos de transação e adaptação. Utiliza dados imobiliários processados da Etapa 2.

3.3.3. KPI 3 — Potencial de Consumo da Região (Demanda / Market Potential)

- `Etapa3.3_analyze_consumption_potential.py` : Carrega e pré-processa dados demográficos, realiza clusterização de regiões com `KMeans` (`Scikit-learn`), treina um modelo preditivo de consumo (`XGBRegressor`) e estima o potencial de receita incremental. Inclui a utilização de `SHAP` para interpretar a importância das features no modelo. Utiliza dados demográficos processados da Etapa 2.

3.3.4. KPI 4 — Custo Operacional Total (TCO por Pedido)

- `Etapa3.4_analyze_operational_cost.py` : Calcula o custo operacional total por pedido, considerando CAPEX amortizado, custo de mão de obra, energia e transporte. Simula a roteirização de frota (com um esqueleto para integração futura com `OR-Tools`) e integra resultados dos KPIs anteriores (tempo de entrega e custo imobiliário) para uma análise abrangente dos custos operacionais.

3.3.5. Integração dos KPIs — Método de Decisão Final (MCDA)

- `Etapa3.5_integrate_kpis_mcda.py` : Este script é central para a tomada de decisão. Ele carrega os resultados dos KPIs individuais, normaliza os valores (min-max), aplica pesos definidos pelos stakeholders e calcula o score TOPSIS (Technique for Order Preference by Similarity to Ideal Solution) para cada cidade. Realiza também uma análise de sensibilidade para avaliar a robustez da decisão frente a variações nos pesos. Os pesos foram atualizados para refletir a prioridade estratégica de 40% para Potencial de Consumo, e 20% para os demais KPIs.
- `ANALISE_DOS_KPIS_MCDA.MD` : Documenta a análise detalhada dos resultados do MCDA, incluindo o ranking, a polarização dos dados, a sensibilidade aos pesos e as recomendações de negócio. Este documento foi atualizado para refletir os pesos definidos pelos stakeholders e os resultados recalculados.

3.3.6. Reprodutibilidade, Validação e Governança

- `Etapa3.6_reproducibility_validation.py` : Configura o rastreamento de experimentos com `MLflow`, carrega e combina dados processados (incluindo geração de dados sintéticos para treinamento de modelos em cenários de escassez de dados reais). Executa experimentos de ML (Gradient Boosting e XGBoost) para previsão de potencial de consumo e custo operacional, registrando métricas e modelos para garantir a reprodutibilidade e rastreabilidade.
- `Etapa3.6.2_utilize_ml_models.py` : Demonstra a utilização dos modelos de machine learning treinados. Carrega modelos do MLflow, prepara dados para previsão, realiza previsões e analisa a importância das features. Compara as cidades com base nas previsões e gera insights de negócio, fechando o ciclo de aplicação dos modelos de ML.

3.4. Etapa 4: Visualização e Comunicação dos Resultados

Esta etapa visa apresentar os resultados de forma clara e interativa.

3.4.1. Construção de Dashboards Interativos

- `app.py` (**Dashboard Streamlit**): Este é o principal entregável interativo da Etapa 4. Desenvolvido com `Streamlit`, ele integra todos os resultados das etapas anteriores em um dashboard web. Permite a exploração dos KPIs individuais, visualização de mapas (isócronas, consumo), comparação de cidades e, crucialmente, a interação com a análise MCDA através de sliders para ajustar os pesos dos KPIs e recalcular o score TOPSIS em tempo real. Inclui gráficos de radar para comparação visual e funcionalidade de exportação de resultados. O `app.py` atua como um protótipo funcional para a comunicação dos resultados.

3.4.2. Elaboração de Relatório Executivo e Preparação de Apresentação para Stakeholders

Embora o `app.py` seja uma ferramenta de visualização, ele serve como base para a elaboração do Relatório Executivo e a preparação de apresentações. Os insights e visualizações gerados pelo dashboard são essenciais para compor esses documentos, que são focados na visão de negócio e na recomendação final.

4. Resultados

4.1. Resultados da Etapa 1

A Etapa 1 resultou na validação dos KPIs, na definição de um plano de projeto detalhado, na seleção de um robusto conjunto de ferramentas e bibliotecas open source, e na estruturação da documentação técnica e executiva. Todos os artefatos desta etapa estão totalmente alinhados com o planejamento inicial, fornecendo uma base sólida para o projeto.

4.2. Resultados da Etapa 2

A Etapa 2 estabeleceu o pipeline ETL para coleta, pré-processamento e armazenamento de dados. Scripts Python foram desenvolvidos para coletar dados imobiliários (web scraping), malha viária (OSRM/Overpass API) e demográficos (IBGE), com mecanismos de simulação para robustez. Os dados foram limpos, transformados (incluindo georreferenciamento) e carregados em um banco de dados PostgreSQL/PostGIS. Um DAG do Apache Airflow (`Etapa2_4_magalu_etl_dag.py`) foi projetado para orquestrar este pipeline. Pontos de atenção identificados incluem a necessidade de melhorar a robustez do web scraping e a dependência de dados simulados devido a falhas de API.

4.3. Resultados da Etapa 3

A Etapa 3 focou na análise e modelagem avançada. Scripts foram desenvolvidos para analisar cada KPI individualmente: `Etapa3.1_analyze_delivery_time.py` (tempo de entrega, isócronas), `Etapa3.2_analyze_real_estate_cost.py` (custo imobiliário, modelo hedônico), `Etapa3.3_analyze_consumption_potential.py` (potencial de consumo, clusterização, modelo preditivo com SHAP) e `Etapa3.4_analyze_operational_cost.py` (custo operacional, simulação de frota). A integração final dos KPIs foi realizada pelo `Etapa3.5_integrate_kpis_mcda.py` usando TOPSIS, com pesos definidos pelos stakeholders (40% Potencial de Consumo, 20% para os demais). A análise de sensibilidade revelou que Salvador é a cidade mais estratégica na maioria dos cenários, com um score TOPSIS de 0.710 contra 0.290 para Recife, embora a decisão seja sensível à priorização do tempo de entrega. A reprodutibilidade foi garantida com `MLflow` (`Etapa3.6_reproducibility_validation.py`, `Etapa3.6.2_utilize_ml_models.py`).

4.4. Resultados da Etapa 4 (Dashboard Streamlit)

O `app.py` desenvolvido em Streamlit serve como a interface interativa para explorar todos os resultados do projeto. Ele apresenta uma visão geral comparativa das cidades, seções detalhadas para cada KPI com visualizações específicas (gráficos de barras, mapas, tabelas) e uma seção de “Cenários de Decisão (TOPSIS)” onde os usuários podem ajustar os pesos dos KPIs e observar o impacto na recomendação final em tempo real, visualizado através de um gráfico de radar. Este

dashboard é uma ferramenta poderosa para a comunicação e validação dos resultados com stakeholders não-técnicos.

5. Discussão

5.1. Interpretação dos Resultados

A análise multicritério, com os pesos definidos pelos stakeholders, indica claramente **Salvador como a localização mais estratégica** para o novo CD do Magalu no Nordeste. Esta recomendação é impulsionada principalmente pelo maior peso atribuído ao Potencial de Consumo da Região, onde Salvador demonstra uma vantagem significativa. Embora Recife apresente vantagens em Custo de Aquisição Imobiliária e Custo Operacional Total (com base nos dados simulados), a priorização do potencial de mercado pelos stakeholders inclina a balança para Salvador.

A análise de sensibilidade reforça esta conclusão, mostrando que Salvador é a vencedora em 5 dos 7 cenários testados, resultando em um score de robustez de 71.4%. No entanto, a análise também revelou que a decisão é sensível ao peso do Tempo Médio de Entrega: se este KPI receber uma prioridade muito alta (acima de 40%), Recife pode se tornar a opção preferencial. Isso sublinha a importância da definição de pesos alinhada à estratégia de negócio.

5.2. Limitações do Estudo e Pontos de Atenção

- **Qualidade dos Dados de Entrada:** Uma limitação significativa é a dependência de dados simulados ou mock para alguns KPIs (especialmente demográficos e de malha viária) devido a desafios na coleta de dados reais (problemas com APIs, web scraping). Isso pode introduzir incertezas nos resultados. A polarização observada na normalização dos dados também é um sintoma dessa limitação.
- **Complexidade da Simulação de Frota:** A simulação de roteirização de frota no KPI de Custo Operacional (`Etapa3.4_analyze_operational_cost.py`) é um esqueleto e não integra plenamente ferramentas de otimização como `OR-Tools` , o que poderia refinar as estimativas de custo.
- **Implementação do Airflow:** Embora um DAG tenha sido projetado, a verificação da sua implantação e funcionamento em um ambiente real do Apache Airflow, bem como a containerização dos jobs, não foi explicitamente demonstrada.
- **Metabase:** O `app.py` é um protótipo em Streamlit. A transição para uma ferramenta de BI de produção como Metabase para a execução final dos dashboards ainda é uma etapa a ser realizada.
- **Fatores Qualitativos:** O estudo focou em aspectos quantitativos. Fatores qualitativos como riscos operacionais, qualidade da infraestrutura local, disponibilidade de mão de obra qualificada e incentivos fiscais não foram explicitamente incorporados na análise MCDA, mas são cruciais para a decisão final.

6. Conclusões

O projeto forneceu uma análise abrangente e metodologicamente robusta para a escolha da localização do novo CD do Magalu no Nordeste. Através da integração de dados, modelagem avançada e análise multicritério, foi possível quantificar o desempenho de Salvador e Recife em relação a KPIs estratégicos. A recomendação final, baseada nos pesos definidos pelos stakeholders, aponta para Salvador como a opção mais vantajosa. O dashboard interativo em Streamlit é uma ferramenta eficaz para explorar e comunicar esses resultados.

7. Recomendações

Com base nas análises e limitações identificadas, as seguintes recomendações são propostas:

- 1. Priorizar a Melhoria da Coleta de Dados:** Investir no aprimoramento dos scripts de web scraping, tratamento de erros de API e georreferenciamento para substituir dados simulados por dados reais e de alta qualidade. Isso aumentará a confiança e a precisão de todas as análises.
- 2. Implementar Otimização de Roteirização:** Integrar plenamente a biblioteca `OR-Tools` no script `Etapa3.4_analyze_operational_cost.py` para simular roteiros de frota de forma mais precisa e otimizada, refinando as estimativas de custo operacional.
- 3. Validar a Implantação do Airflow:** Assegurar que o DAG do Apache Airflow esteja implantado e funcionando corretamente em um ambiente de produção, com monitoramento adequado e jobs containerizados.
- 4. Transição para Metabase (Produção):** Replicar ou migrar os dashboards do Streamlit para o Metabase, conforme planejado, para a execução final e acesso contínuo pelos usuários de negócio.
- 5. Análise Qualitativa Complementar:** Realizar uma análise aprofundada dos fatores qualitativos não incluídos nos KPIs para fornecer uma visão mais holística e mitigar riscos não quantificados.
- 6. Revisar Normalização MCDA:** Explorar métodos de normalização alternativos para o TOPSIS que possam oferecer maior nuance em cenários com poucas alternativas, reduzindo a polarização extrema.

8. Referências Bibliográficas

- `STEP-BY-STEP.MD` - Documento de Planejamento do Projeto.
- Relatórios de Alinhamento das Etapas 1, 2, 3 e 4.
- Documentação das bibliotecas Python utilizadas (Pandas, NumPy, Scikit-learn, XGBoost, Streamlit, Plotly, etc.).
- Documentação do OSRM, Overpass API, IBGE API.

9. Apêndices e Anexos

- `Etapa2_1_1_collect_real_estate_data.py`
- `Etapa2_1_2_collect_road_network_data.py`
- `Etapa2_1_3_collect_demographic_data.py`
- `Etapa2_2_1_preprocess_real_estate_data.py`
- `Etapa2_2_2_preprocess_road_network_data.py`
- `Etapa2_2_3_5_preprocess_demographic_data.py`

- Etapa2_3_1_2_create_db_schema.py
- Etapa2_3_3_load_data_to_db.py
- Etapa2_4_magalu_etl_dag.py
- Etapa3.1_analyze_delivery_time.py
- Etapa3.2_analyze_real_estate_cost.py
- Etapa3.3_analyze_consumption_potential.py
- Etapa3.4_analyze_operational_cost.py
- Etapa3.5_integrate_kpis_mcda.py
- Etapa3.6_reproducibility_validation.py
- Etapa3.6.2_utilize_ml_models.py
- app.py
- ANALISE_DO_DAG.MD
- ANALISE_DOS_KPIS_MCDA.MD
- contexto_reuniao_stakeholders.md
- melhorias_streamlit_nao_tecnicos.md
- modificacoes_necessarias_kpi_pesos.md
- relatorio_alinhamento_etapa1.md
- relatorio_alinhamento_etapa2.md
- relatorio_alinhamento_etapa3.md
- relatorio_alinhamento_etapa4.md